Chapitre 4 - Big Data Project Management & More

1.0 16-12-2024

Pr. Latifa MAHDAOUI

Table des matières

Objectifs 3

I - Le Projet Agile 4

II - Le Projet Big Data 5

Objectifs

- Comprendre ce qu'est un cycle de vie agile, en exemple Scrum
- Saisir le concept de projet Big Data et ses activités
- Avoir une idée sur les métiers autour des sciences des données
- L'importance de la collaboration dans le montage des projets
- Donner quelques clarifications sur les plateformes de gestion de projet modernes

I Le Projet Agile

Les approches modernes en matière de génie logiciel

Fondamental

Les documents du chapitre III (sur Moodle), vous donnent une idée sur le monde du génie logiciel (Software Engineering) et les différents modèles de cycles de vie qui ont été proposés pour gérer des projets de développement de logiciels.

Cependant, la tendance actuelle encourage les cycles de vie agiles qui sont des modèles basées sur la **flexibilité**, la **collaboration**, l'**efficacité** et la **rapidité** dans le processus de production de logiciels ou systèmes IT.

Regardons ensemble cette vidéo qui présente une des méthodes agiles les plus utilisées dans les projets de développement (elle est appliquée en Algérie depuis quelques années) ...

Lien vers vidéo : https://youtu.be/Rx11ISvyKK8

Notons, qu'en plus de Scrum, il existe d'autres méthodes comme KANBAN et SAFe entre autres. Scrum se caractérise par sa rigueur et sa bonne structure organisationnelle.

Les plateformes de gestion de projets agiles

Complément

Il existe beaucoup d'outils et plateformes logicielles permettant la gestion de projets agiles tels que : Jira, Click UP, Confluence, ... etc.

Ce sont des systèmes permettant le suivi de bout en bout les étapes du projet qui seront définies en sprint tel que chaque sprint devra fournir un livrable au client.

II Le Projet Big Data

Quels sont les métiers liés au domaine Big Data ?

Fondamental

Nous distinguons principalement :

1. Les métiers liés à la collecte et au stockage des données
2. Les métiers liés au traitement et à l'analyse des données
3. Les métiers liés à la protection et à la sécurisation des données

1. Les métiers liés à la collecte et au stockage des données

Data engineer

- Il a pour rôle de récolter et de préparer les données, afin que les autres spécialistes du traitement et de l'analyse des données (Data Analyst, Data Scientist…) puissent les exploiter.
- Il conçoit et administre les systèmes de collecte de données, et s'occupe de les organiser une fois qu'elles ont été collectées. Il épaule le Data Scientist en lui garantissant un accès facile et rapide à toutes les données collectées.
- Ses compétences sont très variées : il doit maîtriser les langages dédiés à la donnée comme SQL, ainsi que les outils de stockage des données. Mais il doit également être familier des langages de programmation généralistes comme Python et avoir des connaissances en statistiques et en Machine Learning (pour être capable de comprendre ce que le Data Scientist va faire avec les données)

Le CDO (Chief Data Officer)

- Il gère les interactions entre la direction de l'entreprise et le département chargé de l'analyse data. Il assure l'accès des dirigeants aux bases de données et aux résultats des analyses menées. Parallèlement, il dirige les opérations d'analyse, optimise la gestion des données et contrôle la qualité du travail effectué par les Data Analysts et Data Scientists.
- Il doit pour cela bien connaître le secteur économique de l'entreprise, les outils d'analyse des données (PowerBI, langages SQL et Python) ainsi que les principes mathématiques qui les sous-tendent. Enfin, il fait preuve de leadership car il dirige les travaux des Data Scientists.

Le Data Miner

- Il a pour mission d'explorer les données qui sont à la disposition de l'entreprise, pour trouver celles qui sont utiles à son entreprise. Lorsqu'il a trouvé des données qui méritent d'être analysées, il les formate afin de les rendre exploitables. Il travaille donc en étroite collaboration avec le Data Analyst et le Data Scientist. Il peut même parfois porter plusieurs casquettes !
- Ses compétences sont la maîtrise des outils de stockage des données, ainsi que des connaissances en statistiques pour pouvoir anticiper sur le travail du Data Analyst.

L'architecte Big Data

- Il supervise la récupération, la gestion et le stockage des données. Il doit être capable d'optimiser tous ces processus, et de réaliser des inventaires des données disponibles qu'il soumettra aux dirigeants ou au Chief Data Officer.

- Pour cela, il maîtrise les technologies du Big Data telles que : les langages de la Data Science comme Python, les systèmes de gestion NoSQL comme Cassandra, les outils de stockage des données comme Memtables, les infrastructures serveurs comme Hadoop ou Spark.

2. Les métiers liés au traitement et à l'analyse des données

Le Data Analyst

- Il exploite et analyse les données recueillies par l'entreprise. Il peut également enrichir les sets de données, en utilisant une API ou les techniques du web scraping. Son super-pouvoir est de rendre un grand volume de données intelligibles pour les managers : le Data Analyst "**fait parler les données**".
- Son savoir-faire repose sur la maîtrise d'outils tels que Python et SQL. Python est un langage de programmation très polyvalent, et qui dispose de nombreuses bibliothèques dédiées à la data analyse. SQL (Structured Query Language) est un langage dédié à la manipulation de grands volumes de données stockées dans des bases de données relationnelles.
- Le Data Analyst doit également maîtriser la data visualisation. Elle lui permet de présenter ses données et son analyse sous forme de graphiques (ou même d'animations), qui seront parlants pour ses interlocuteurs. Il a également un rôle de conseil sur la stratégie de l'entreprise

Le Data Scientiste

- Tout comme le Data Analyst, le Data Scientiste a pour mission d'exploiter les données recueillies par l'entreprise et il est amené à interagir avec les différents services de l'entreprise (stratégie, marketing, finance). A la différence du Data Analyst, le Data Scientist a souvent une approche plus théorique de l'analyse de données. Il est chargé d'établir des modèles statistiques d'analyse de données commerciales, que le Data Analyst pourra ensuite utiliser. Le Data Scientist est également celui qui va établir les modèles prédictifs à partir des données qu'on lui fournit.
- C'est pourquoi un Data Scientist doit pouvoir justifier de compétences solides en mathématiques, statistiques mais aussi codage. Il sait utiliser Python, R et il est à l'aise avec le Machine Learning (apprentissage automatique). Il maîtrise les outils de datavisualisation et est doté d'un bon sens du relationnel puisqu'il doit faire remonter ses analyses aux managers.

Le Data Manager

- Il doit veiller à ce que les données soient accessibles pour tous les collaborateurs qui en ont besoin, et à ce qu'elles soient utilisables. Par exemple, c'est lui qui met en place des processus techniques pour que, lorsqu'un Data Analyst travaille sur un set de données, cela n'empêche pas les autres Data Analysts d'accéder à ce même set !
- Il vérifie également la qualité des données, et leur conformité face aux lois comme le RGPD (Règlement Général sur la Protection des Données).
- Il doit pour cela connaître les langages de programmation tels que Python, R et SQL, ainsi que les systèmes de gestion de base de données comme PostgreSQL. Il doit en outre avoir une bonne connaissance du secteur d'activité de l'entreprise.

Le Machine Learning Engineer

- Il est programmateur en informatique. Il est spécialisé dans le Machine Learning, une discipline qui permet aux machines d'effectuer automatiquement des tâches pour lesquelles elles n'ont pas été spécifiquement programmées (elles se programment elles-mêmes).

- Il doit donc disposer de solides compétences en mathématiques : analyse, algèbre linéaire, statistiques et probabilités. Il maîtrise les langages de programmation (Python, R) ainsi que les applications cloud. En analyse des données, il est capable de développer des réseaux de neurones profonds, ainsi que des modèles complexes pour les données non structurées (images et langage naturel).

3. Les métiers liés à la protection et à la sécurisation des données

Le DPO (Data Protection Officer)

- Il est doté d'une double casquette :

- S'assurer que les données de l'entreprise, en particulier les données sensibles, sont à l'abri des intrusions malveillantes

- S'assurer que ces données (leur stockage et leur utilisation) respectent les règlements en vigueur, notamment le RGPD.

- Il doit donc disposer de compétences dans plusieurs domaines : informatique, cybersécurité, expertise juridique.

Le Data Steward

- Il est responsable de la maniabilité et de la qualité de la data qui est à la disposition des Data Analysts. Il doit s'assurer qu'elle est triée, organisée, mais surtout issue d'une source fiable.
- Pour cela, il met en place des systèmes de détection et de contrôle des données. Il gère également l'accès aux données : il crée des process spécifiques pour déterminer qui a accès à quelle base de données.
- Il doit donc maîtriser les outils de gestion des données comme SQL, Python ainsi que les systèmes d'information sur le cloud.

Comment doit-on aborder un projet Big Data en milieu professionnel ?

Fondamental

Les projets de type Big Data sont des projets informatiques liés principalement aux données et à tout type de traitement qui sont en relation avec les sciences des données.

Cependant, il y a lieu de savoir qu'il y a généralement deux aspects à considérer dans ce type de projet : (i) technologique et (ii) professionnel (enjeu métier).

Suivons cette vidéo qui remonte à 10 ans déjà ...

Lien vers Vidéo : https://youtu.be/LGfd1YXWrRA

Comme nous pouvons le constater, la partie métier nécessite beaucoup plus d'effort pour convaincre les décideurs de l'utilité de cette technologie, même si aujourd'hui les responsables sont conscients des enjeux en matière d'utilisation de la donnée pour analyser des comportements et des phénomènes pouvant contribuer à l'amélioration des processus, un meilleur choix des stratégies et cela va de soi, une meilleure prise de décision.

Relation entre les projets Big Data et les méthodes agiles

Exemple

Un projet Big Data possède des spécificités différentes de celle d'un projet de développement d'un produit logiciel. Il y a lieu alors de bien réfléchir sur la manière d'organiser son projet, ses activités, ses ressources, ... etc.

Suivons attentivement cette présentation ...

Lien vers Vidéo : https://youtu.be/sv2eOCx-P-E